

PRÁCTICAS APLICADAS EN ANÁLISIS DE DATOS

Caso práctico: Predicción de churn en telecom

Empresa: Unión Central Voz

1. Introducción

Este proyecto consiste en el desarrollo de un **caso práctico de ciencia de datos** centrado en la predicción del churn en una empresa ficticia del sector telecomunicaciones.

El caso ha sido diseñado para que el alumnado trabaje sobre un **ecosistema de datos coherente y realista**, en lugar de datasets aislados, reproduciendo así el flujo de trabajo típico de un equipo de data science en entorno profesional.

El objetivo principal es:

Comprender, modelizar y predecir la probabilidad de abandono de clientes (churn) a partir de múltiples fuentes de información.

2. Objetivos de aprendizaje

El caso está diseñado para cubrir múltiples competencias clave dentro de un máster en ciencia de datos:

2.1. Análisis exploratorio de datos (EDA)

- Comprensión de distribuciones
- Detección de outliers
- Análisis de correlaciones
- Comparación entre segmentos
- Estrategia de imputación de valores faltantes

2.2. Feature engineering

- Construcción de variables temporales (lags, rolling)
- Agregaciones por cliente y zona
- Generación de ratios y métricas derivadas
- Integración de múltiples fuentes

2.3. Modelado predictivo

- Clasificación (churn, impago)
- Regresión (facturación)
- Comparación entre modelos lineales y no lineales

2.4. Series temporales

- Análisis de evolución temporal
- Detección de patrones
- Uso de información pasada para predicción

2.5. NLP (Procesamiento de lenguaje natural)

- Análisis de sentimiento
- Extracción de tópicos
- Uso de texto no estructurado en modelos

2.6. Pensamiento causal y prevención de leakage

- Identificación de variables predictivas vs consecuencias
- Uso correcto de información temporal
- Diseño de modelos realistas

3. Narrativa de negocio

El caso se sitúa en una empresa de telecomunicaciones donde el churn es un problema crítico.

El abandono de clientes está influido por múltiples factores:

- calidad de la red,
- incidencias técnicas,
- experiencia con atención al cliente,
- comportamiento de pago,

- percepción subjetiva del servicio.

Esto permite construir un problema **multicausal y realista**, adecuado para entrenamiento avanzado y ofreciendo al alumnado la posibilidad de tomar diferentes estrategias a la hora de responder a una misma pregunta.

4. Filosofía de diseño del dataset

El dataset ha sido construido siguiendo una premisa fundamental:

Los datos deben ser sintéticos, pero no arbitrarios.

Esto implica:

- Relaciones causales coherentes
- Dependencias entre variables
- Persistencia temporal
- Ruido realista
- Ausencia de leakage

El churn no es una etiqueta aleatoria, sino el resultado de la interacción de múltiples procesos.

5. Estructura del dataset

El ecosistema de datos está compuesto por varias tablas interrelacionadas.

5.1. Calidad de red

Archivo: `calidad_senal_zona_mensual.csv`

Descripción

Datos agregados por zona y mes que reflejan el estado de la red.

Variables

- Cobertura 4G / 5G
- Latencia

- Velocidad
- Tasa de cortes
- Incidencias masivas

Características de diseño

- Persistencia temporal
- Tendencias (ej. mejora del 5G)
- Eventos puntuales
- Diferencias estructurales entre zonas

Objetivo docente

- Series temporales
 - Análisis territorial
 - Feature engineering
-

5.2. Clientes

Archivo: `clientes.csv`

Descripción

Información estructural de los clientes.

Variables

- Zona
- Edad, sexo, estado civil
- Número de líneas
- Tipo de plan
- Dispositivo
- Ingresos
- Antigüedad
- Descuentos

Características de diseño

- Variables correlacionadas (no independientes)
- Segmentación realista

Objetivo docente

- Clustering
- Segmentación

- Variables explicativas base
-

5.3. Facturación mensual

Archivo: `facturacion_mensual.csv`

Descripción

Panel cliente-mes con comportamiento económico.

Variables

- Cargo base
- Consumo extra
- Importe total
- Impagos
- Retrasos de pago
- Variación de consumo

Diseño clave

La facturación depende también de la calidad de red:

- Mala calidad → menor consumo
- Mala calidad → mayor impago

Modelo conceptual

$$CONSUMO_T = f(plan, cliente, calidad_{t-1})$$

Objetivo docente

- Regresión
 - Series temporales
 - Ingeniería de variables económicas
-

5.4. Interacciones de soporte

Archivo: `interacciones_soporte.csv`

Descripción

Eventos de contacto con atención al cliente.

Variables

- Canal
- Motivo
- Resolución
- Duración
- Satisfacción post-contacto

Diseño

- Más interacciones si:
 - mala calidad,
 - impagos,
 - incidencias
- Satisfacción depende de resolución y contexto

Decisión clave

Un cliente puede churnear sin llamar nunca.

Objetivo docente

- Modelado de eventos
 - Agregaciones temporales
 - Análisis de experiencia de cliente
-

5.5. Encuestas con texto

Archivo: `encuestas_texto.csv`

Descripción

Encuestas anónimas mensuales por zona.

Características clave

- Muestra limitada (~1000 encuestas)
- Representatividad por zona
- No se pueden unir a cliente individual

Variables

- Puntuación general

- NPS
- Texto libre

Diseño

- Texto dependiente del contexto
- Posible incongruencia entre rating y texto

Objetivo docente

- NLP
 - Inferencia a partir de muestras
 - Construcción de señales agregadas
-

5.6. Churn

Archivo: `churn_target.csv`

Descripción

Panel cliente-mes con etiqueta de churn.

Características

- Churn mensual (no agregado)
- Desbalanceado (~20% churn)
- Basado en múltiples factores

Variables explicativas implícitas

- Factores estructurales
- Factores económicos
- Factores técnicos
- Factores relacionales
- Señales textuales

Diseño clave

Censura temporal:

- No hay datos después del churn

Esto evita leakage y simula entorno real.

6. Estructura causal del sistema

El sistema simula un pipeline real de generación de churn:

1. Perfil del cliente → vulnerabilidad base
 2. Calidad de red → experiencia técnica
 3. Experiencia → comportamiento económico
 4. Problemas → interacciones de soporte
 5. Percepción → encuestas
 6. Todo lo anterior → churn
-

7. Decisiones pedagógicas clave

7.1. No simplificar en exceso

No se proporciona una variable resumen directa (ej. calidad global).

7.2. Introducir ruido

El problema no es perfectamente predecible.

7.3. Evitar leakage

Uso de:

- lags
- rolling windows
- censura tras churn

7.4. Multifuente

Los alumnos deben integrar varias tablas.

7.5. Realismo controlado

Equilibrio entre:

- realismo
 - claridad pedagógica
-

8. Fortalezas del caso

- Alta coherencia interna
 - Narrativa clara
 - Multimodalidad
 - Temporalidad correcta
 - Escalable en dificultad
 - Cercano a un caso real
-

9. Limitaciones

- Sigue siendo un dataset sintético
 - Mecanismo generador relativamente limpio
 - Posible explotación por alumnos avanzados
 - NLP no dominante
-

10. Estrategias posibles de los alumnos

Un alumno avanzado puede:

- Simplificar el problema temporal
- Detectar variables clave
- Usar modelos lineales bien ajustados
- Ignorar NLP
- Modelar como survival discreto

Esto no invalida el caso, pero debe tenerse en cuenta en evaluación.

11. Posibles actividades docentes

Nivel básico

- EDA
- Segmentación

Nivel intermedio

- Feature engineering
- Modelos básicos

Nivel avanzado

- Modelos temporales
- NLP
- Interpretabilidad

Nivel profesional

- Recomendaciones de negocio
-

12. Evaluación

Para la evaluación de la asignatura se tendrá en cuenta:

- Calidad de las memorias entregadas o notebooks: 60%
 - Estructura
 - Discusiones y explicación a la hora de tomar decisiones
 - Calidad y diseño de las gráficas
 - Metodología clara
- Participación en clase: 5%
- Asistencia a clase: 5%
- Presentación final de resultados: 30%

13. Conclusión

Este proyecto constituye un:

caso integrador de ciencia de datos con enfoque profesional

que permite al alumnado trabajar con:

- datos realistas,
- múltiples fuentes,
- problemas no triviales,
- y decisiones metodológicas relevantes.

